# Don Cándido IA

Presentación de Producto — Solución Corporativa

Un producto exclusivo de **Alte 4 Consultoría**

Brindamos Asesoramiento Estratégico, Tecnología Avanzada, Optimización de Procesos y Normas de Calidad Internacionales.

VENTAS B2B

# Don Cándido IA — Sistema de Inteligencia Artificial Omnicanal

> *Fecha: 2026-03-16 | Proyecto: 9001app-firebase | Estado: Producción*

## ¿Qué es?

Don Cándido es el asistente de inteligencia artificial del ecosistema SaaS ISO 9001. Es un agente conversacional **omnicanal y multi-tenant** que opera como consultor experto en calidad, gestión de procesos y operaciones organizacionales. Funciona simultáneamente en tres canales: **chat web, voz y WhatsApp**.

---

## Stack Tecnológico Principal

| Capa | Tecnología | Uso |
|---|---|---|
| LLM primario | **Anthropic Claude** (claude-3-5-sonnet) | Análisis de auditorías, generación de documentos, calidad |
| LLM fallback/fast | **Groq + Llama 3.3 70B** | Chat rápido, operaciones de agente |
| TTS / Voz | **ElevenLabs** (eleven_multilingual_v2) | Voz personalizada "Don Cándido" |
| STT / Transcripción | **Web Speech API** | Reconocimiento de voz en navegador |
| WhatsApp | **Meta WhatsApp Business API v19** | Canal externo de mensajería |
| Base de datos | **Firestore** | Historial de conversaciones, identidades |
| Framework | **Next.js 14 + TypeScript** | API routes, UI, SSR |
| Seguridad Webhook | **HMAC-SHA256** | Verificación de mensajes WhatsApp |

---

## Arquitectura del Sistema

### 1. UnifiedConverseService — El Cerebro

`src/services/ai-core/UnifiedConverseService.ts`

Servicio central que orquesta todos los canales. Responsabilidades:

- Construye el **system prompt** con contexto de la organización (misión, visión, sector, tamaño)
- Inyecta contexto del usuario (cargo, departamento, supervisor)
- Inyecta documentación interna relevante ( `content/docs/` )
- Gestiona historial de conversación (últimos 20 mensajes)
- Estima y controla tokens consumidos
- Escribe/lee desde `ai_conversations` en Firestore

### 2. LLMRouter — Routing Multi-Proveedor

`src/ai/services/LLMRouter.ts`

| Capacidad | Proveedor Primario | Fallback |
|---|---|---|
| `chat_general` | Groq (2-3s latencia) | Claude |
| `audit_eval` | Claude (20-30s) | Groq |
| `doc_gen` | Claude | Groq |
| `agent_ops` | Groq | Claude |

Incluye métricas de latencia, tracking de intentos y flags de disponibilidad por env var.

### 3. Adapters — Interfaces por Canal

`src/services/ai-core/adapters/`

- **ChatAdapter** — Chat web con contexto de pantalla y módulo activo
- **VoiceAdapter** — Transcripciones de voz o URLs de audio
- **WhatsAppAdapter** — Mensajes entrantes sin autenticación requerida (resolución de identidad por número)

---

## Canales de Comunicación

### Chat Web

- Endpoint: `POST /api/chat/messages`
- Módulos con contexto inyectado: `mi-panel`, `rrhh`, `procesos`, `documentos`, `crm`, `auditorias`, `hallazgos`, `acciones`, `don-candido`
- Modos: `fast` (Groq + tool calling) / `quality` (Claude estructurado)
- Feature flag: `ENABLE_UNIFIED_AI_CHAT_CORE`

### Voz (TTS/STT)

- Endpoint TTS: `POST /api/elevenlabs/speech`
- Voice ID: `kulszILr6ees0ArU8miO` (voz personalizada Don Cándido)
- Fallback voice: `pNInz6obpgDQGcFmaJgB` (Adam)
- Rate limit: 8 requests / 60s por organización
- Componente: `MiPanelVoiceAssistant.tsx` con controles mic/speaker
- Hook: `useVoicePlayer.ts` para reproducción de audio

### WhatsApp Externo

- Webhook entrada: `POST /api/public/whatsapp/webhook` (público, sin auth)
- Verificación HMAC: `timingSafeEqual` con `WHATSAPP_APP_SECRET`
- Cliente salida: `WhatsAppClient.ts` → Meta Graph API v19
- Colecciones Firestore: `whatsapp_conversations`, `whatsapp_messages`
- Resolución de identidad: número de teléfono → usuario interno
- **ElevenLabs Conversational Agent:** agente directo de voz para WhatsApp ( `ELEVENLABS_AGENT_ID_DON_CANDIDO` )

---

## Integraciones con CRM e ISO 9001

### Tools (Herramientas de Agente)

`src/services/ai-core/tools/`

| Tool | Descripción |
|---|---|
| `createNC` | Crear No Conformidad directamente desde el chat |
| `getDashboardData` | Consultar métricas del dashboard de calidad |
| `getPendingTasks` | Listar tareas pendientes del usuario |
| `navigateUserTo` | Navegar la UI del usuario (comando de interfaz) |

### Context Builder

`src/ai/services/ContextBuilder.ts`

Perfiles de contexto disponibles:

- **chat** — Conversación general con datos de la organización
- **evaluation** — Análisis de auditorías y hallazgos
- **document** — Generación de documentos ISO
- **agent_ops** — Operaciones y tareas del agente

Fuentes de contexto inyectadas:

- Estado de cumplimiento ISO (brechas, pendientes, madurez)
- Datos del personal (cargo, departamento, supervisor)
- Asignaciones (procesos, objetivos, indicadores)
- Base de conocimiento en Markdown (39 archivos, 13 módulos)

---

## Prompts Versionados

`src/ai/prompts/`

| Prompt | Versión | Propósito |
|---|---|---|
| `iso-action-recommendation` | v1 | Recomendaciones de planes de acción |
| `iso-document-generation` | v1 | Guía para crear documentos ISO |
| `iso-gap-evaluation` | v1 | Análisis de brechas de cumplimiento |
| `iso-indicator-analysis` | v1 | Análisis de indicadores de calidad |

Cada prompt tiene su schema Zod correspondiente para validación de output estructurado.

---

## Seguridad y Política

### Policy Engine

`src/services/ai-core/policyEngine.ts`

- Bloqueo de aprobación de documentos para roles sin permisos
- Bloqueo de eliminación de procesos para roles sin permisos
- Análisis de contenido con regex

### Idempotency Guard

`src/services/ai-core/idempotencyGuard.ts`

- Previene procesamiento duplicado del mismo mensaje
- Cache por `clientMessageId` por canal

### Seguridad Multi-Tenant

- `withAuth` en todas las rutas de IA
- `resolveAuthorizedOrganizationId` para aislamiento por org
- Rate limiting en endpoints de voz
- HMAC en webhook WhatsApp

---

## Telemetría y Monitoreo

`src/ai/telemetry/`

Eventos trackeados:

- `request_started` / `request_succeeded` / `request_failed`
- `fallback_used` — cuando se activa el proveedor secundario
- `schema_validation_failed` — errores de output estructurado

Métricas: proveedor, modelo, latencia, tokens, intentos.

---

## Base de Conocimiento Interna

`content/docs/` — 39 archivos Markdown, 13 módulos cubiertos

Módulos documentados: `mi-panel`, `rrhh`, `procesos`, `documentos`, `crm`, `auditorias`, `hallazgos`, `acciones`, `don-candido`, `app-cliente`, `app-vendedor`, `dealer`, `crm/satisfaccion-nps`

El contenido se inyecta dinámicamente en el system prompt según la pantalla activa del usuario.

---

## Variables de Entorno Clave

```
ANTHROPIC_API_KEY              # Claude API
GROQ_API_KEY                   # Groq Llama
ELEVENLABS_API_KEY             # TTS ElevenLabs
ELEVENLABS_VOICE_ID            # Voice ID Don Cándido
WHATSAPP_ACCESS_TOKEN          # Meta WhatsApp Business API
WHATSAPP_APP_SECRET            # Verificación HMAC webhook
ELEVENLABS_AGENT_ID_DON_CANDIDO # Agente WhatsApp voz
ENABLE_UNIFIED_AI_CHAT_CORE    # Feature flag nuevo core IA
```

---

## Estado de Producción (2026-03-16)

| Componente | Estado |
|---|---|
| Chat web con tools | ✅ Operacional |
| TTS ElevenLabs | ✅ Operacional |
| STT navegador | ✅ Operacional |
| WhatsApp webhook | ✅ Configurado (falta apuntar en Meta) |
| ElevenLabs Agent WhatsApp | ✅ Configurado (falta activar en Meta) |
| LLM Routing Claude/Groq | ✅ Operacional |
| Knowledge base 39 docs | ✅ Operacional |
| Telemetría | ✅ Activa (PostHog) |
| Multi-tenant aislamiento | ✅ Operacional |

**Alte 4 Consultoría**

Asesoramiento • Tecnología • Procesos • Normas de Calidad